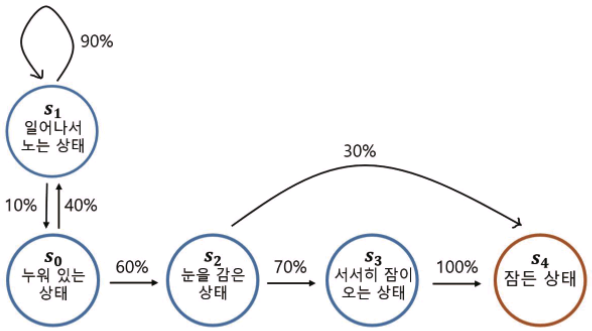
2. 마르코프 프로세스

2.1. 마르코프 프로세스(Markov Process)

아이가 잠이 드는 마르코프 프로세스



| 그림 2-1 | 아이가 잠이 드는 마르코프 프로세스

- 상태전이(state transition); 현재 상태에서 다음 상태로 넘어감
  - 위 예제에서 s_0에서 s_1로 상태전이될 확률은 40%, s_2로 상태전이될 확률은 60%
- 마르코프 프로세스는 종료상태(예제에선 s_4)에 도달하면 끝이 남
- 마르코프 프로레스는 미리 정의된 어떤 확률 분포를 따라서 상태와 상태 사이를 이동해 다니는 여정

마르코프 프로세스의 요소

- 상태집합: $S = s_0, s_1, \ldots, s_n$
- 전이확률 행렬: P_{ss'} = P[S_{t+1}=s'|S_t=s]
  - 상태 s에서 다음 상태 s'에 도착할 확률
    - 예제에서 $P_{s_0 s_2} = 0.6$
- 전이확률 행렬: P = $\begin{pmatrix} & s_0 & s_1 & s_2 & s_3 & s_4 \\ s_0 & & 0.4 & & & \\ s_1 & 0.1 & 0.9 & & & \\ s_2 & & & & 0.7 & 0.3 \\ s_3 & & & & & 1.0 \\ s_4 & & & & & 1.0 \end{pmatrix}$

마르코프 성질

- "미래는 오로지 현재에 의해 결정된다"
- P_{ss'} = P[S_{t+1}=s'|S_t=s]

마르코프한 상태

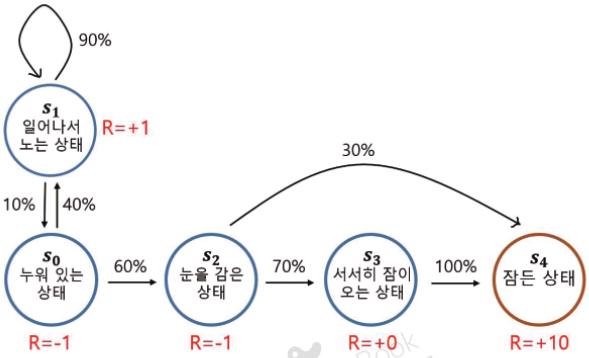
- 체스 게임; 현재 상태만으로 모든 상황 파악

마르코프하지 않은 상태

- 운전사의 상태: 현재 상태만으로 모든 상황파악 불가
  - 최근 10초 동안의 사진 10장: 마르코프 상태 가까움
  - 속도, 가속도 추가정보 제공: 마르코프 성질 더욱 만족
    - → 마르코프하지 않은 상태도 마르코프하도록 근사할 수 있긴 함
- → 단일 상태만으로 모든 상황 파악이 가능하도록 해야 함

2.2. 마르코프 리워드 프로세스(MRP: Markov Reward Process)

아이가 잠이 드는 MRP



| 그림 2-4 | 아이가 잠에 드는 MRP

- 마르코프 프로세스에 보상 개념 추가
- 상태 별로 보상을 받음
- 상태의 집합: MRP ≡ (S, P, R, γ)
  - 보상 함수: $R = E(R_t|S_t = s)$
    - 어떤 상태 S에 도착했을 때 받게 되는 보상
  - 감쇠 인자 : 미래 얻을 보상에 비해 당장 얻는 보상을 얼마나 중요하게 여길지를 나타내는 파라미터
    - 0 ≤ γ ≤ 1
    - 미래에 받는 보상에 대한 감쇠

감쇠된 보상의 합: 리턴

- 에피소드: 하나의 여정을 나타낸 것
- 에피소드를 활용해 리턴 정의

$$G_t = R_{t+1} + \gamma R_{t+2} + \ldots + \gamma^{T-1} R_T$$

γ의 필요성

- γ가 없으면(즉, γ=1이면) 무한대로 발산 가능
- 또는 γ=0이면 미래의 보상은 모두 0이 되버림
- 사람의 선호 반영 가능
  - 시간적으로 빠른 보상이 더 좋은 것임을 반영할 수 있음
- 미래에 대한 불확실성 반영 가능

각 상태의 가치 평가하기

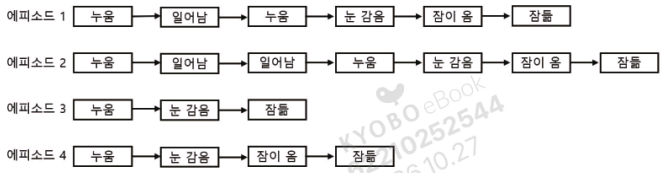
- 상태의 가치는 받은 보상으로 평가할 수 있음
  1. 그 상태에 올 때까지 받은 보상으로 평가?
     - 그 상태 이전에 많은 보상을 받았다는 것이 목적 상태에 가깝다는 것을 의미하지는 않음
  2. 그 상태 이후에 받을 보상으로 평가? (이것이 더 합리적임)
     - 목적 상태에 가까울수록 그 상태의 가치가 큼
     - 특정 상태 이후에 받을 보상 → 앞에서 이야기한

리턴

- 상태의 가치는 리턴으로 측정할 수 있음
  - 리턴은 측정할 때마다 달라짐 (측정할 때마다 종료 상태까지 경로가 달라짐으로)
  - 리턴의 기댓값으로 측정

에피소드의 샘플링

- 몬테 카를로 접근법 사용



| 그림 2-7 | 아이 재우기 MRP의 에피소드 샘플들

- $v(s) = E(G_t|S_t = s)$
- 누움 상태 s_0의 상태 가치
  - s_0에서 시작하는 에피소드를 모아서 기댓값 구함
    - ∑ 발생확률 * 리턴 값

2.3. 마르코프 결정 프로세스(MDP: Markov Decision Process)

- MP나 MRP로는 순차적 모델링 불가능
  - → MDP 사용. 기존 MRP에 액션 A 추가

MDP의 정의

$$MDP \equiv (S, A, P, R, \gamma)$$

- 상태 집합 S: MP, MRP와 동일
- 액션 집합 A: 에이전트가 취할 수 있는 액션들을 모아놓은 집합
- 전이확률행렬 $P^A_{SS'}$: 현재 상태가 s일때 에이전트가 액션 a를 선택했을 때 다음 상태 s'이 될 확률

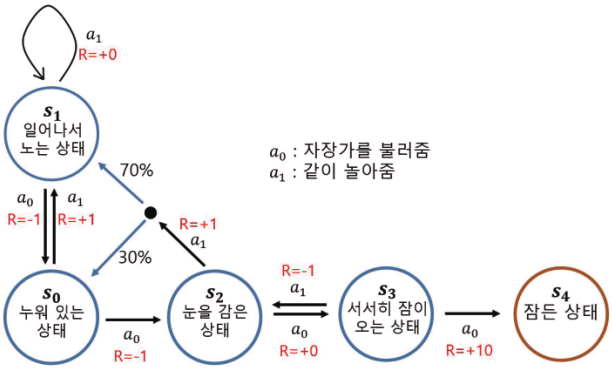
$$P^A_{SS'} = P[S_{t+1} = s'|S_t = s, A_t = a]$$

- 보상함수 R:

$$R^a_s = E[R_{t+1}|S_t = s, A_t = a]$$

- 감쇠인자 γ

아이 재우기 MDP



| 그림 2-9 | 아이 재우기 MDP

$$P^{a_1}_{s_2,s_0} = 0.3, P^{a_1}_{s_2,s_1} = 0.7$$

정책 함수와 2가지 함수

정책 함수

- 정책 함수(Policy function); 각 상태에서 어떤 액션을 선택할지 정해주는 함수

$$\pi(a|s) = P(A_t = a|S_t = s)$$

$$(\sum \pi(a|s) = 1)$$

상태 가치 함수

- 상태 가치 함수(State value function): s부터 끝까지 π를 따라서 움직일 때 얻는 리턴의 기댓값

$$v_\pi(s) = E_\pi(r_{t+1} + \gamma r_{t+2} + \ldots + |S_t = s) = E_\pi(G_t|S_t = s)$$

액션 가치 함수

- 액션 가치 함수(action value function): 상태 가치 함수에서 액션 추가

$$q(s, a) = E_\pi)(G_t|S_t = s, A_t = a)$$

2.4. Prediction과 Control

- MDP($MDP \equiv (S, A, P, R, \gamma)$)이 주어졌을 때 관심있는 2가지
  - Prediction: π가 주어졌을 때 각 상태의 밸류를 평가하는 문제
  - Control: 최적 정책 π*를 찾는 문제

그리드 월드 문제

출발	s_1	s_2	s_3
s_4	s_5	s_6	s_7
s_8	s_9	s_{10}	s_{11}
s_{12}	s_{13}	s_{14}	종료

보상 : 스텝마다 -1

정책 : 4방향 uniform 랜덤

| 그림 2-12 | 격자 세상, 영어로는 그리드 월드(Grid World)

$$\forall s \in S$$
$$\pi(Direction|s) = 0.25,\ Direction = east \wedge west \wedge south \wedge north$$

- γ가 1일 때 에피소드마다 다양한 보상을 받을 수 있음

$$s_{11} \rightarrow \text{종료}, \quad \text{리턴} = -1$$
$$s_{11} \rightarrow s_{10} \rightarrow s_{14} \rightarrow \text{종료}, \quad \text{리턴} = -3$$
$$s_{11} \rightarrow s_7 \rightarrow s_6 \rightarrow s_{10} \rightarrow s_{11} \rightarrow \text{종료}, \quad \text{리턴} = -5$$
$$s_{11} \rightarrow s_7 \rightarrow s_3 \rightarrow s_2 \rightarrow s_3 \rightarrow s_2 \rightarrow s_6 \rightarrow s_{10} \rightarrow s_9 \rightarrow s_{13} \rightarrow s_{14} \rightarrow s_{10} \rightarrow s_{14} \rightarrow \text{종료}, \quad \text{리턴} = -13$$

- Control 문제에서 목적은 최적 정책 π*을 찾는 것
  - 즉 리턴이 큰 π를 찾는 것
  - 이를 찾기 위해 강화학습 사용