3. 벨만 방정식

재귀 함수

- 재귀적 관계에 대한 식
  - 예시: 피보나치 수열

$$fib(x) = \begin{cases} 1\ (x <= 1) \\ fib(x-1) + fib(x-2)\ else \end{cases}$$

3.1. 벨만 기대 방정식

0. 먼저 한 스텝만큼 진행하여 보상을 받고 그 다음 상태인 s_{t+1} 부터 미래에 받을 보상을 더해줘도 똑같음

$$v_{pi}(s_t) = E_\pi\left(r_{t+1} + \gamma v_\pi(s_{t+1})\right)$$
$$q_\pi(s_t, a_t) = E_\pi\left(r_{t+1} + \gamma q_\pi(s_{t+1}, a_{t+1})\right)$$

1. q_π를 이용해 v_π 계산
   - 상태 s에서 선택할 수 있는 a의 경우의 확률을 합함
   - v_π를 이용해 q_π 계산하기 → 각 상태의 밸류를 아는 상태

$$v_\pi(s) = \sum_{a \in A} \pi(a|s) q_\pi(s,a)$$
$$q_\pi(s,a) = r_s^a + \gamma \sum_{s \in S} P_{ss'}^a v_\pi(s')$$

2. 1단계의 q 수식에 v 수식 대입

$$v_\pi(s) = \sum_{a \in A} \pi(a|s) \left(r_s^a + \gamma \sum_{s \in S} P_{ss'}^a v_\pi(s') \right)$$
$$q_\pi(s,a) = r_s^a + \sum_{s' \in S} P_{ss'}^a \sum_{a' \in A} \pi(a'|s') q_\pi(s', a')$$

- 위 수식을 사용하기 우해서 보상함수와 전이확률을 반드시 알아야 함
  - 보상함수 r_s^a: 각 상태에서 액션을 선택하면 얻는 보상
  - 전이확률 $P_{ss'}^a$: 각 상태에서 액션을 선택하면 다음 상태가 어디가 될 지에 관한 확률분포
- 그러나 모델 프리 환경에서는 이 둘을 모르는 경우가 훨씬 많음
  - 모델 프리 접근법(경험을 통한 학습) 사용

3.2. 벨만 최적 방정식

- 벨만 최적 방정식은 $v_*(s)$와 $q_\pi(s,a)$에 대한 수식

$$v_*(s) = max_\pi v_\pi(s)$$
$$q_*(s,a) = max_\pi q_\pi(s,a)$$

- -> 어떤 MDP가 주어졌을 때 그 MDP 안에 존재하는 모든 π 중에서 가장 좋은 π를 선택하여 계산한 밸류가 곧 최적 밸류 $v_*(s)$라는 뜻
- 최적 정책: 모든 정책 $\pi_1, \pi_2, \ldots, \pi_\infty$중에서 제일 좋은 정책
  - "제일 좋은"의 의미: 최적 정책 π_*를 따를 때 얻는 보상이 가장 큼

벨만 최적 방정식

0. $v_*(s) = \max_a E[r, +\gamma v_*(s') \mid s_t = s a_t = a] q_*(s,a) = E[r, +\gamma \max_{a'} q_*(s', a') \mid s_t = s a_t = a]$

- 벨만 기대 방정식의 0단계와의 차이점: E_π에서 E로 바뀜
  - π가 없다는 것은 모든 액션을 선택 가능하다는 것. 즉 모든 정책 중 최적 정책인 $E[r + \gamma v_*(s')]$의 값을 크게 함

1. $.v_*(s) = \max_a q_*(s,a) q_*(s,a) = r_s^a + \gamma \sum_{s' \in S} P_{ss'}^a v_*(s')$
   - q_*를 이용해 v_*를 계산
     - q_*는 각 액션을 선택했을 때 얻는 최적 밸류
   - v_*를 이용해 q_*를 계산

2. $.v_*(s) = \max_a \left[r_s^a + \gamma \sum_{s' \in S} P_{ss'}^a v_x(s') \right] q_*(s,a) = r_s^a + \gamma \sum_{s' \in S} P_{ss'}^a \max_{a'} q_*(s', a')$
   - v_*식에 $q_*(s,a)$식을 대입